

Procesamiento de mamografías para remoción de tejido muscular

Andrea Carolina Terraza Sequea¹, Chiara Vivian Valenzuela Losada¹ y Laura Catalina García¹

¹Procesamiento de Imágenes, Universidad Sergio Arboleda, Bogotá D.C, Colombia

Keywords: Cáncer de mama, Mamografía, Procesamiento de imágenes, Remoción, Tejido muscular, Análisis

Abstract: El cáncer de mama afecta a millones de mujeres en todo el mundo y la detección temprana es fundamental para mejorar las tasas de supervivencia y la eficacia del tratamiento. La mamografía toma un papel importante en el diagnóstico temprano, ya que permite a los especialistas hallar anomalías en el tejido mamario que pueden indicar neoplasias malignas. Sin embargo, la interpretación de las mamografías se enfrenta a retos como el ruido, el bajo contraste y la presencia de zonas irrelevantes, que complican la identificación precisa de las lesiones. Este proyecto tiene como finalidad mejorar las condiciones para el análisis de las mamografías mediante técnicas de procesamiento de imágenes que se centran en la eliminación del tejido muscular. Se espera que, luego de aplicar las técnicas de procesamiento, se tengan mamografías más claras al eliminar estructuras no deseadas, lo que ayudará a identificar masas de manera más eficaz.

1. Introducción

El tipo de cáncer que más muertes causa a nivel mundial es el de mama. Según la Organización Mundial de la Salud, cada año se diagnostican alrededor de 2.3 millones de casos, y aproximadamente 685,000 mujeres pierden la vida debido a esta enfermedad [Organización Mundial de la Salud, 2024]. En este contexto, la detección temprana es importante para mejorar la tasa de supervivencia y la efectividad del tratamiento. Las mamografías son una herramienta fundamental, porque permiten a los especialistas identificar anomalías en el tejido mamario que podrían indicar la presencia de tumores malignos.

En las mamografías, especialmente en la proyección mediolateral oblicua (MLO), es común que aparezca el músculo pectoral, que puede ocupar una parte significativa de la imagen. Este tejido, al tener características visuales similares al tejido mamario, complica la segmentación y el análisis automatizado. Además, en otras proyecciones, como la craneo-caudal (CC) y mediolateral (ML), las estructuras cercanas a los bordes, como músculo y huesos, también pueden interferir en el análisis [Avci and Karakaya, 2023]. La presencia de estas áreas no deseadas puede generar diagnósticos menos precisos, aumentar el riesgo de falsos positivos o negativos, y complicar la tarea de los especialistas [Li et al., 2013].

A pesar de la relevancia de las mamografías en la detección temprana del cáncer de mama, la interpretación y análisis de estas imágenes presentan múltiples desafíos técnicos, como se explicó. Entre ellos, algunos dificultan la segmentación precisa del tejido mamario, afectando tanto a los

diagnósticos clínicos como a los sistemas de detección automatizados. En este contexto, diversos estudios han propuesto métodos computacionales para abordar esta problemática, con enfoques que van desde algoritmos clásicos de segmentación hasta técnicas híbridas y avanzadas.

El problema abordado en "Developing an Improved Method to Remove Pectoral Muscle for Better Diagnosis of Breast Cancer in Mammography Images" es la interferencia del músculo pectoral en las mamografías, que dificulta la segmentación precisa de tejidos mamarios y afecta negativamente al diagnóstico automatizado del cáncer de seno. Para resolverlo, se exploraron dos algoritmos de segmentación: Level Set y Region Growing, y se propuso una versión mejorada del algoritmo Region Growing (IRG), con umbral dinámico para mejorar la precisión en la detección del músculo pectoral. Los métodos se probaron en el conjunto de datos MIAS, alcanzando el IRG una precisión de hasta el 83 %, superando significativamente a Level Set. Sin embargo, las limitaciones incluyeron dificultades en imágenes con artefactos o contornos poco visibles del músculo, y ambos algoritmos mostraron un desempeño limitado con ciertos tipos de mamografías complejas, subrayando la necesidad de futuras mejoras mediante técnicas avanzadas como redes neuronales profundas para la segmentación [Abaei et al., 2023].

En "Pectoral Muscles Removal in Mammogram Image by Hybrid Bounding Box and Region Growing Algorithm" indican que la interferencia del músculo pectoral en mamografías complica la segmentación precisa de la región de interés (ROI) para el diagnóstico de cáncer de mama. Para abordar esta dificultad, los autores propusieron un algoritmo

mo híbrido denominado HBBRG, que combina las técnicas de Bounding Box (BB) y Region Growing (RG). Este método mejora la precisión al aprovechar las fortalezas de ambos enfoques, reduciendo sus limitaciones individuales. Los resultados experimentales, obtenidos mediante el conjunto de datos MIAS, demostraron que el HBBRG alcanzó una precisión superior al 98 % en la eliminación del músculo pectoral, superando los métodos BB y RG aplicados de forma separada. Sin embargo, el método BB mostró limitaciones al usar una forma triangular fija, lo que no se adapta a todas las imágenes, mientras que el RG fue menos efectivo en imágenes densas o glandulares debido a la similitud de intensidad entre los tejidos. Estas limitaciones enfatizan la importancia de una optimización continua del algoritmo para mejorar su aplicabilidad en escenarios variados [Saeed and Saleh, 2020].

La conferencia organizada por la Universidad de Puerto Rico Mayaguez Campus en 2021 habló de cómo la inspección de mamografías digitales es una de las técnicas más utilizadas para la detección temprana de anomalías en el tejido mamario humano; sin embargo, la presencia del músculo pectoral, especialmente en las vistas mediolaterales oblicuas (MLO), representa un desafío al interferir en el análisis computacional y la discriminación entre tejido mamario y estructuras adyacentes. Para abordar este problema, se propuso un método de dos etapas que incluye la eliminación de elementos ruidosos, como etiquetas, marcadores y arañosos, y la aplicación de una transformación de intensidad basada en la distribución Beta para resaltar las áreas relevantes de la imagen. Este enfoque, que fue validado con 322 mamografías digitales de la base de datos mini-MIAS, ha demostrado un desempeño sólido en la identificación y eliminación del músculo pectoral, mejorando la precisión de los algoritmos de detección y optimizando el análisis automático del tejido mamario [Ayala, 2020].

El principal desafío que trata el proyecto propuesto en este artículo es implementar técnicas de procesamiento de imágenes que permitan la eliminación del músculo pectoral y otras estructuras cercanas a los bordes de las mamografías, sin recurrir a algoritmos de aprendizaje automático. La solución debe aplicar una serie de técnicas de preprocesamiento y segmentación que actúen directamente sobre las áreas no deseadas, mejorando la claridad de las zonas donde se encuentra el tejido mamario. El objetivo es obtener mamografías limpias, con el músculo pectoral eliminado de manera precisa. Al centrarse en conservar exclusivamente las áreas que contienen tejido mamario, se espera que estas técnicas faciliten el análisis posterior y aumenten la precisión del diagnóstico. Este enfoque no solo busca superar las limitaciones de los métodos existentes, sino también contribuir al desarrollo de herramientas más robustas y efectivas para el diagnóstico temprano del cáncer de mama.

2. Metodología

2.1. Descripción de las imágenes

En este proyecto se usarán imágenes provenientes del conjunto de datos *Curated Breast Imaging Subset of the Digital Database for Screening Mammography* (CBIS-DDSM), una base de datos ampliamente reconocida y utilizada en el ámbito de la investigación de cáncer de mama. Este dataset contiene imágenes de mamografías digitales obtenidas a partir de exámenes de detección de cáncer de mama con una amplia gama de casos, desde imágenes normales hasta aquellas con diversas anomalías [Sawyer-Lee et al., 2016].

2.1.1. Modalidad y formato

Las imágenes son mamografías digitales en formato DICOM, aunque se van a transformar a un formato JPG, lo que asegura una alta calidad y mejor procesamiento de las imágenes. Incluyen vistas cráneo-caudal (CC), medio-lateral (ML) y medio-lateral oblicua (MLO) de cada seno.

2.1.2. Anotaciones y etiquetado

Las imágenes están etiquetadas y anotadas para indicar la presencia de lesiones sospechosas, como masas y microcalcificaciones. También, proporcionan información adicional sobre el tipo de lesión (benigna o maligna).

2.1.3. Resolución y calidad

El dataset incluye imágenes de diferentes calidades, lo que permite evaluar la robustez de los algoritmos en situaciones de imágenes con diferentes niveles de ruido y contraste. Las mamografías usadas cuentan con una alta resolución, lo que permite un análisis detallado del tejido mamario.

2.2. Pipeline de procesamiento

Para este proyecto se usarán las imágenes de proyección MLO pertenecientes al conjunto de datos CBIS-DDSM. Estas imágenes requieren ser procesadas para manejar su variabilidad y segmentar correctamente las regiones de interés. El pipeline, ver Figura 1, se enfoca en eliminar el tejido muscular, empleando varias técnicas de procesamiento, entre ellas la morfología matemática, ya que esta última facilita la segmentación precisa del músculo pectoral y su separación del tejido mamario [Zebari et al., 2020].

2.2.1. Escalar la imagen (interpolación bilineal)

El primer paso del preprocesamiento ilustrado es el escalado de la imagen, que se realiza con el fin de ajustar el tamaño a uno más manejable que facilite el procesamiento. Dicho escalado se hace mediante interpolación bilineal, técnica que permite cambiar el tamaño de manera suave. Esta técnica calcula los valores de los nuevos píxeles usando

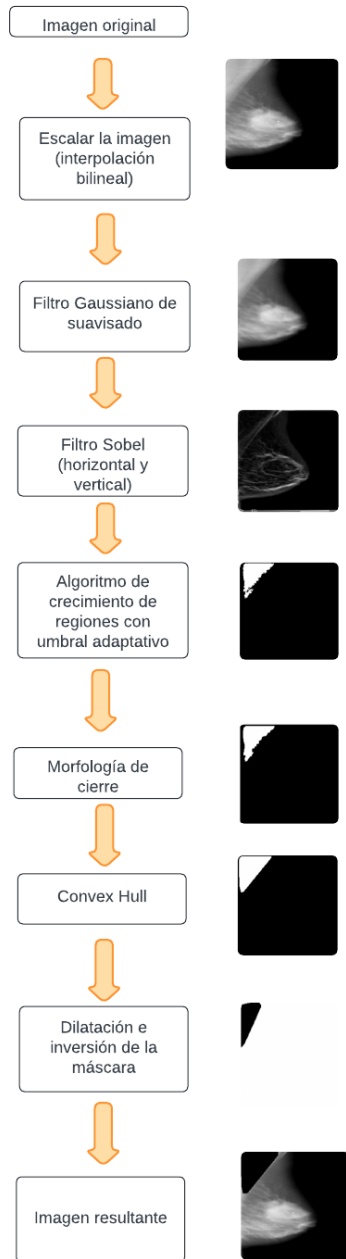


Figura 1: La imagen muestra el flujo de preprocesamiento de las mamografías, destacando cada una de las etapas involucradas; se puede observar el estado inicial de la imagen, seguido por el escalado de la imagen, desenfoco gaussiano, filtro Sobel, algoritmo de crecimiento por regiones con umbral adaptativo, morfología de cierre, Convex Hull y, finalmente, dilatación junto a la inversión de la máscara, para la eliminación del tejido muscular.

los valores de los cuatro más cercanos, en la imagen original, como referencia. A diferencia de otros métodos más simples, la interpolación bilineal promedia los valores de es-

tos píxeles vecinos para asignar un valor al nuevo píxel, lo que resulta en una transición suave entre los diferentes tonos y bordes de la imagen escalada, manteniendo la calidad visual [Capital, 2024].

2.2.2. Filtro gaussiano de suavizado

El segundo paso tiene la finalidad de reducir el ruido que más adelante puede interferir con la segmentación del tejido mamario. El filtro aplicado usa una convolución de distribución gaussiana, lo que se traduce en que los píxeles en un punto específico reciben más peso en el promedio que los píxeles alejados. Lo anterior suaviza la imagen, es decir, elimina pequeños detalles irrelevantes, permitiendo que los algoritmos de segmentación y detección de bordes se enfoquen mejor en las estructuras significativas, como los bordes del tejido mamario [Zebari et al., 2022].

2.2.3. Filtro Sobel (horizontal y vertical)

Tercer paso de procesamiento, el filtro Sobel, técnica utilizada en la detección de bordes, identificando cambios abruptos en la intensidad entre diferentes regiones de una imagen. Se basa en la aplicación de dos máscaras 3x3 para obtener los bordes en la dirección horizontal y otra en la vertical, las cuales permiten obtener los gradientes G_x y G_y , respectivamente. La magnitud del gradiente se obtiene combinando ambos resultados mediante la raíz cuadrada de la sumatoria de los gradientes al cuadrado, lo que permite resaltar los bordes con mejor precisión. Este filtro tiene capacidad limitada para detectar bordes en ángulos no horizontales o verticales y no es tan robusto como el filtro Canny, pero aún así permite la detección de los bordes necesarios para la tarea de segmentación [Sapate and Talbar, 2016].

2.2.4. Algoritmo de crecimiento de regiones con umbral adaptativo

Como cuarto paso del pipeline de procesamiento, se usa el algoritmo de crecimiento de regiones con umbral adaptativo. El cual se implementa con el fin de segmentar una imagen basada en similitudes de intensidad de los píxeles y la magnitud de sus gradientes. El proceso comienza a partir de un punto semilla seleccionado en la imagen (que puede ajustarse si no cumple ciertos criterios), que en este caso es en (10,10), y a partir de ahí, el algoritmo expande la región evaluando píxeles vecinos para determinar si deben ser incluidos en la región segmentada.

El criterio de inclusión de nuevos píxeles se basa en dos factores principales: la diferencia de intensidad entre el píxel actual y el promedio de la región en crecimiento (en este caso con un valor de 20), y el valor del gradiente en ese píxel (en este caso 30). La intensidad controla que los píxeles añadidos sean similares en tonalidad a los que ya están en la región, mientras que el gradiente evalúa la presencia de bordes o cambios bruscos en la imagen. Un umbral adaptativo ajusta

la sensibilidad del gradiente según la diferencia de intensidad local, permitiendo que el algoritmo sea más o menos estricto dependiendo de las características de la imagen en esa zona.

El algoritmo de crecimiento de regiones con umbral adaptativo aplicado a las mamografías permite identificar áreas de interés, como el tejido mamario, mientras excluye estructuras no deseadas, como el músculo. Durante el proceso, la imagen de la mamografía cambia al irse marcando solo las regiones que cumplen con los criterios de similitud de intensidad y gradiente, lo que resulta en una máscara que elimina el músculo que por lo general tiene una intensidad más alta de píxeles comparado con todo el tejido mamario [Abaei et al., 2023].

2.2.5. Morfología de cierre

Para el quinto paso se usa el cierre morfológico, una operación utilizada para suavizar contornos, rellenar pequeños huecos y conectar componentes cercanos en una imagen binaria. Se define como la dilatación de la imagen seguida por una erosión, aplicando en ambos pasos un elemento estructurante definido. En este caso, se utilizó un kernel de 5x5; la dilatación expande los bordes de los objetos, mientras que la erosión posterior corrige este efecto, eliminando pequeñas irregularidades sin afectar la forma general. Esta técnica es útil para conectar elementos fragmentados y eliminar ruido [Nagi et al., 2010].

2.2.6. Convex Hull

El sexto paso, Convex Hull, se utiliza para mejorar la forma en que se segmenta el tejido mamario. Después de identificar las áreas relevantes en la imagen, esta técnica ayuda a suavizar los bordes de estas regiones, creando una envoltura convexa que elimina cualquier irregularidad y llena espacios. Esto es importante porque asegura que toda el área del tejido mamario esté bien definida y se mantenga intacta para el análisis, evitando que se pierdan partes relevantes durante el proceso de segmentación. Al aplicar el Convex Hull, se obtiene una imagen más limpia y precisa del tejido mamario, lo que facilita la identificación de posibles anomalías [Naz et al., 2017].

2.2.7. Dilatación de la máscara

Como séptimo paso en el procesamiento se encuentra la dilatación de máscara, que tiene como objetivo expandir los bordes de los objetos presentes en una imagen binaria, incrementando las áreas blancas y reduciendo pequeñas regiones negras o huecos internos. Esta técnica es útil para conectar elementos fragmentados, resaltar estructuras y eliminar pequeños defectos en los contornos. En este caso, se usa un kernel de 5x5 y se aplica la dilatación que expande los bordes de las estructuras presentes en la máscara. La elección del kernel y del número de iteraciones influye directamente

en el grado de expansión, permitiendo controlar con precisión el resultado en función de la tarea específica, como la mejora de contornos o la unión de regiones cercanas.

2.2.8. Inversión de la máscara

Finalmente, la inversión de máscara permite modificar las regiones de interés. Intercambiando los valores de los píxeles binarios (de blanco a negro y viceversa). En este caso, se aplica esta operación para conservar el tejido mamario relevante y eliminar el tejido muscular no deseado en las mamografías.

3. Resultados

En esta sección se presentan los resultados obtenidos tras aplicar las técnicas de procesamiento de imágenes enfocadas en la eliminación del tejido muscular en mamografías. La comparación entre las imágenes originales y las procesadas muestra que se ha logrado preservar únicamente el tejido mamario, eliminando estructuras innecesarias. A continuación, se encuentran los resultados mediante varias imágenes correspondientes a proyecciones mediolateral oblicua (MLO) tanto del seno izquierdo como del derecho. Estas imágenes permiten identificar cómo las técnicas aplicadas responden en diferentes orientaciones y casos anatómicos.




Figura 2: En esta imagen procesada se logró eliminar el tejido muscular de manera precisa, sin dejar residuos ni áreas claras en los bordes y el tejido mamario se ha preservado completamente.

La Figura 2 muestra un ejemplo exitoso donde el tejido muscular fue eliminado con precisión, sin dejar residuos significativos en los bordes y preservando íntegramente el tejido mamario. Este resultado destaca la capacidad del método para separar de forma clara las estructuras anatómicas de interés. En contraste, la Figura 3 ilustra un caso en el que, si bien se logró eliminar la mayor parte del tejido muscular, permanecen pequeñas áreas en los bordes con intensidades similares al tejido mamario. Esto indica que, aunque el método es robusto, podría beneficiarse de ajustes adicionales para mejorar la separación completa entre ambas estructuras. De manera similar, en la Figura 4 se observa




Figura 3: En la imagen procesada se ha eliminado con éxito la mayor parte del tejido muscular, especialmente en la esquina superior izquierda. Sin embargo, aún queda una pequeña región en los bordes del tejido muscular donde algunas áreas se vuelven más claras, con intensidades cercanas al tono del tejido mamario. Estos resultados reflejan una mejora significativa, aunque podrían requerir ajustes adicionales para optimizar completamente la separación entre ambas estructuras.




Figura 4: Se logró eliminar la mayor parte del tejido muscular, preservando únicamente el tejido mamario. Sin embargo, en la parte derecha persisten algunas áreas claras, lo que indica que no se alcanzaron a captar con precisión todos los bordes del tejido muscular. A pesar de este detalle, el procesamiento ha reducido significativamente las estructuras no deseadas, mejorando en gran medida la claridad de la imagen.

que, aunque se eliminó una gran parte del tejido muscular, persisten áreas claras en el borde derecho de la imagen, lo que sugiere una captura imprecisa en algunos bordes. No obstante, el método redujo significativamente las estructuras no deseadas, logrando una mejora notable en la claridad general de la imagen. Por otro lado, la Figura 5 refleja un caso menos favorable, donde las técnicas empleadas no lograron eliminar por completo el músculo pectoral. Esto podría deberse a la similitud de intensidades entre el músculo y el tejido mamario en esta proyección específica, resaltando la necesidad de ajustar los parámetros para escenarios más complejos. Finalmente, la Figura 6 presenta un resultado altamente satisfactorio, donde el músculo pectoral fue eliminado de manera efectiva, sin residuos relevantes, y el te-




Figura 5: Se observa que persisten áreas del tejido muscular que no fueron eliminadas por completo en la imagen resultante. Esto se debe a que el criterio utilizado, que asume que el tejido muscular es la región de mayor intensidad, no se cumple en su totalidad en esta proyección. Como resultado, solo una parte del tejido muscular fue eliminada, mientras que algunas secciones permanecen visibles.




Figura 6: La imagen final muestra un buen resultado, logrando eliminar de manera efectiva el tejido muscular sin dejar residuos significativos. El proceso ha cumplido con su objetivo, manteniendo únicamente el tejido mamario relevante para el análisis.

jido mamario se mantuvo completamente preservado. Este último caso evidencia el potencial del método para generar imágenes de alta calidad, ideales para análisis posteriores.

En conjunto, los resultados obtenidos demuestran que las técnicas de procesamiento aplicadas son efectivas en la mayoría de los casos para eliminar el tejido muscular, manteniendo las áreas relevantes para el análisis diagnóstico. Sin embargo, algunas imágenes revelaron limitaciones relacionadas con el umbral de segmentación, particularmente en proyecciones donde el contraste entre el músculo y el tejido mamario es menos marcado. Por lo tanto, aunque se ha logrado una segmentación adecuada en muchos casos, estos hallazgos resaltan la importancia de ajustar los parámetros según las características específicas de cada imagen y de considerar un enfoque adaptable que pueda manejar la variabilidad anatómica presente en las mamografías. Esto podría incluir el uso de técnicas más avanzadas, como métodos basados en aprendizaje profundo, para mejorar la precisión y robustez del procesamiento.

4. Conclusión

El uso de técnicas de procesamiento de imágenes, como la segmentación y morfología matemática, ha demostrado ser eficaz para eliminar el tejido muscular pectoral de las mamografías. Al eliminar el músculo pectoral, se optimiza la segmentación del tejido mamario. Esto facilita el trabajo de los radiólogos y mejora la precisión de los diagnósticos, reduciendo el riesgo de falsos positivos y negativos, que son comunes cuando se enfrenta ruido o estructuras irrelevantes.

La combinación de métodos como el algoritmo de crecimiento de regiones con umbral adaptativo, junto con la morfología de cierre y el Convex Hull, ha permitido una segmentación eficiente y precisa de las áreas de interés en las mamografías. Los resultados experimentales confirman que estas técnicas pueden eliminar con eficacia el músculo pectoral sin comprometer la calidad del tejido mamario visible. Sin embargo, aunque los métodos propuestos han mostrado buenos resultados en la mayoría de los casos, se identificaron limitaciones en imágenes con artefactos o bordes poco visibles del músculo. Esto destaca la necesidad de seguir mejorando y adaptando las técnicas de procesamiento para casos más complejos, como mamografías con alta densidad de tejido glandular. También se subraya la importancia de continuar explorando métodos avanzados, como redes neuronales profundas, para mejorar la segmentación y aumentar la aplicabilidad de estos enfoques en diferentes tipos de mamografías. La combinación de procesamiento clásico con técnicas de aprendizaje automático podría ser el camino a seguir para optimizar aún más los diagnósticos automáticos.

5. Referencias

- [Abaei et al., 2023] Abaei, G., Rezaei, Z., Mian, U. Q., Abdalla, Y. A. A., Mathew, N., and Gan, L. Y. (2023). Developing an improved method to remove pectoral muscle for better diagnosis of breast cancer in mammography images. *International journal of advanced computer science and applications: IJACSA*.
- [Avcı and Karakaya, 2023] Avcı, H. and Karakaya, J. (2023). A novel medical image enhancement algorithm for breast cancer detection on mammography images using machine learning. *MDPI, Escuela de medicina de la Universidad Hacettepe*.
- [Ayala, 2020] Ayala, J. A. (2020). Eliminación automática del músculo pectoral en mamografías según sus características anatómicas. In *Universidad de Puerto Rico Mayaguez Campus, Facultad de Artes y Ciencias, Departamento de Ciencias Matemáticas*.
- [Capital, 2024] Capital, F. (2024). Interpolacion bilineal el metodo de interpolacion bilineal remodelacion de datos de excel. *fastercapital.com*.
- [Li et al., 2013] Li, Y., Chen, H.-J., Yang, Y., and Yang, N. (2013). Pectoral muscle segmentation in mammograms based on homogenous texture and intensity deviation. *Pattern Recognition*, 46:681–691.
- [Nagi et al., 2010] Nagi, J., Abdul Kareem, S., Nagi, F., and Khaleel Ahmed, S. (2010). Automated breast profile segmentation for roi detection using digital mammograms. In *2010 IEEE EMBS Conference on Biomedical Engineering and Sciences (IECBES)*, page 87–92. IEEE.
- [Naz et al., 2017] Naz, S. I., Shah, M., and Bhuiyan, M. I. H. (2017). Automatic segmentation of pectoral muscle in mammogram images using global thresholding and weak boundary approximation. In *2017 IEEE International WIE Conference on Electrical and Computer Engineering (WIECON-ECE)*, pages 199–202.
- [Organización Mundial de la Salud, 2024] Organización Mundial de la Salud (2024). Breast cancer. *OMS*.
- [Saeed and Saleh, 2020] Saeed, E. M. H. and Saleh, H. A. (2020). Pectoral muscles removal in mammogram image by hybrid bounding box and region growing algorithm. In *2020 International Conference on Computer Science and Software Engineering (CSASE)*, pages 146–151.
- [Sapate and Talbar, 2016] Sapate, S. and Talbar, S. (2016). *An Overview of Pectoral Muscle Extraction Algorithms Applied to Digital Mammograms*, pages 19–54. Springer International Publishing, Cham.
- [Sawyer-Lee et al., 2016] Sawyer-Lee, R., Gimenez, F., Hoogi, A., and Rubin, D. (2016). Curated breast imaging subset of digital database for screening mammography (cbis-ddsm) [data set]. *The Cancer Imaging Archive*.
- [Zebari et al., 2022] Zebari, D. A., Haron, H., Sulaiman, D. M., Yusoff, Y., and Mohd Othman, M. N. (2022). Cnn-based deep transfer learning approach for detecting breast cancer in mammogram images. In *2022 IEEE 10th Conference on Systems, Process Control (ICSPC)*, page 256–261. IEEE.
- [Zebari et al., 2020] Zebari, D. A., Zeebaree, D. Q., Abdulazeez, A. M., Haron, H., and Hamed, H. N. A. (2020). Improved threshold based and trainable fully automated segmentation for breast cancer boundary and pectoral muscle in mammogram images. *IEEE*, 46:681–691.